



손에 잡히는 딥러닝

Convolutional Neural Networks



모두의연구소

박은수 Research Director

큰 그림 : 구조



- LeNet (1998년)




전형적인 구조

CONV POOL FC

LeNet 1



모두의연구소




큰 그림 : 컨볼루션은 ...

컨볼루션 필터 : 이미지의 특징을 추출할 수 있다

-1	0	1
-1	0	1
-1	0	1

수직 에지를 찾는
컨볼루션 필터



큰 그림 : 컨볼루션은 ...


컨볼루션 필터 : 이미지의 특징을 추출할 수 있다

수직 에지를 찾는
컨볼루션 필터

0

-1	0	1			
-1	0	1			
-1	0	1			

100



0			

큰 그림 : 컨볼루션은 ...

컨볼루션 필터 : 이미지의 특징을 추출할 수 있다

수직 에지를 찾는
컨볼루션 필터


0

100

	-1	0	1		
	-1	0	1		
	-1	0	1		

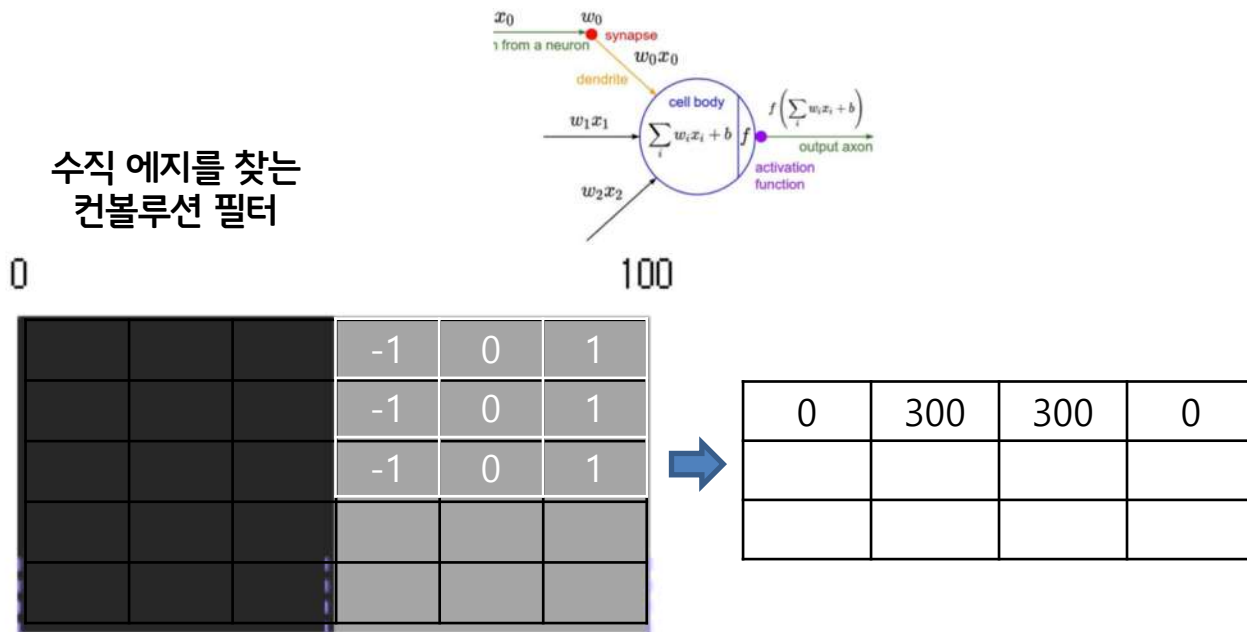


0	300		



큰 그림 : 컨볼루션은 ...

컨볼루션 필터 : 이미지의 특징을 추출할 수 있다



큰 그림 : 컨볼루션은 ...

컨볼루션 필터 : 이미지의 특징을 추출할 수 있다

수직 에지를 찾는
컨볼루션 필터


0

100

-1	0	1			
-1	0	1			
-1	0	1			



0	300	300	0
0			




큰 그림 : 컨볼루션은 ...

컨볼루션 필터 : 이미지의 특징을 추출할 수 있다


수직 에지를 찾는
컨볼루션 필터

0

100



0	300	300	0
0	300		




큰 그림 : 컨볼루션은 ...

컨볼루션 필터 : 이미지의 특징을 추출할 수 있다


수직 에지를 찾는
컨볼루션 필터

0

100



0	300	300	0
0	300	300	




큰 그림 : 컨볼루션은 ...

컨볼루션 필터 : 이미지의 특징을 추출할 수 있다


수직 에지를 찾는
컨볼루션 필터

0

100




0	300	300	0
0	300	300	0
0	300	300	0



큰 그림 : 컨볼루션은 ...

컨볼루션 필터 : 이미지의 특징을 추출할 수 있다



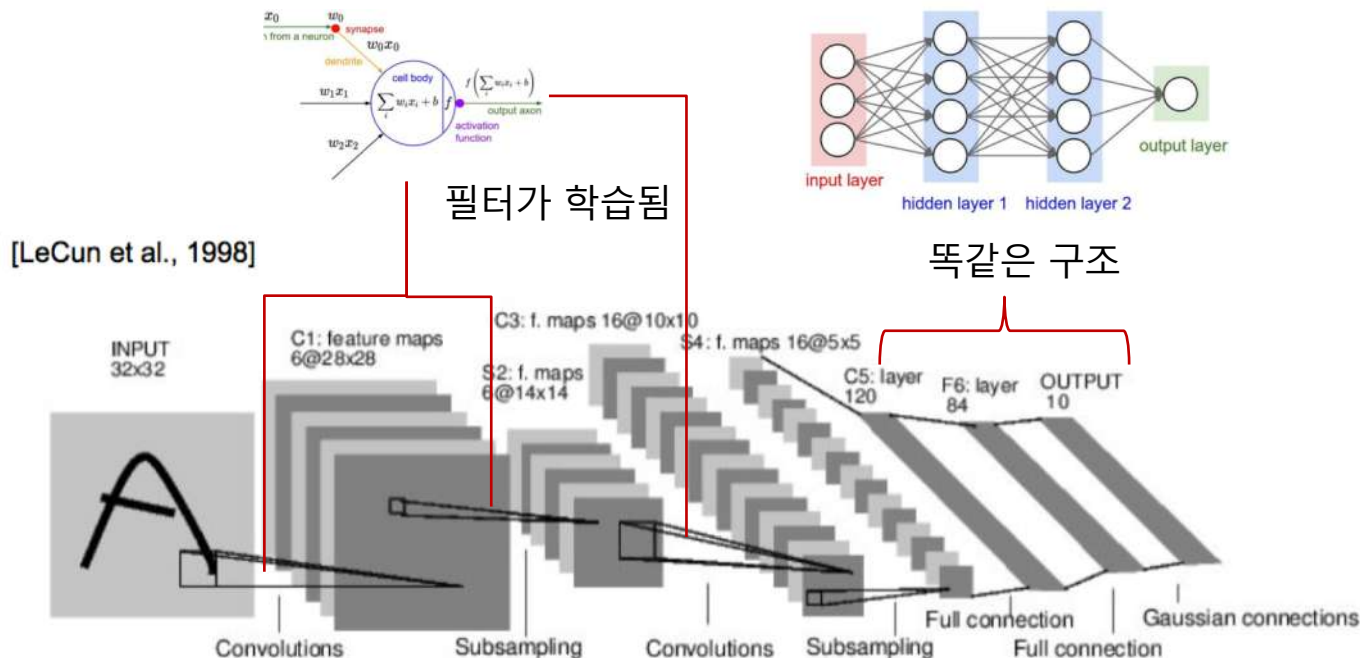
다양한 필터로 다양한
특징을 추출할 수 있다

- 위에 보여드린 예시의 구현입니다

3_conv2d_example.ipynb

컨볼루셔널 뉴럴넷 (Convolutional Neural Network)


- 필터를 학습하는 구조다



이제부터 자세히 살펴봅시다


Convolution Layer

32x32x3 image -> preserve spatial structure



Convolution Layer

32x32x3 image

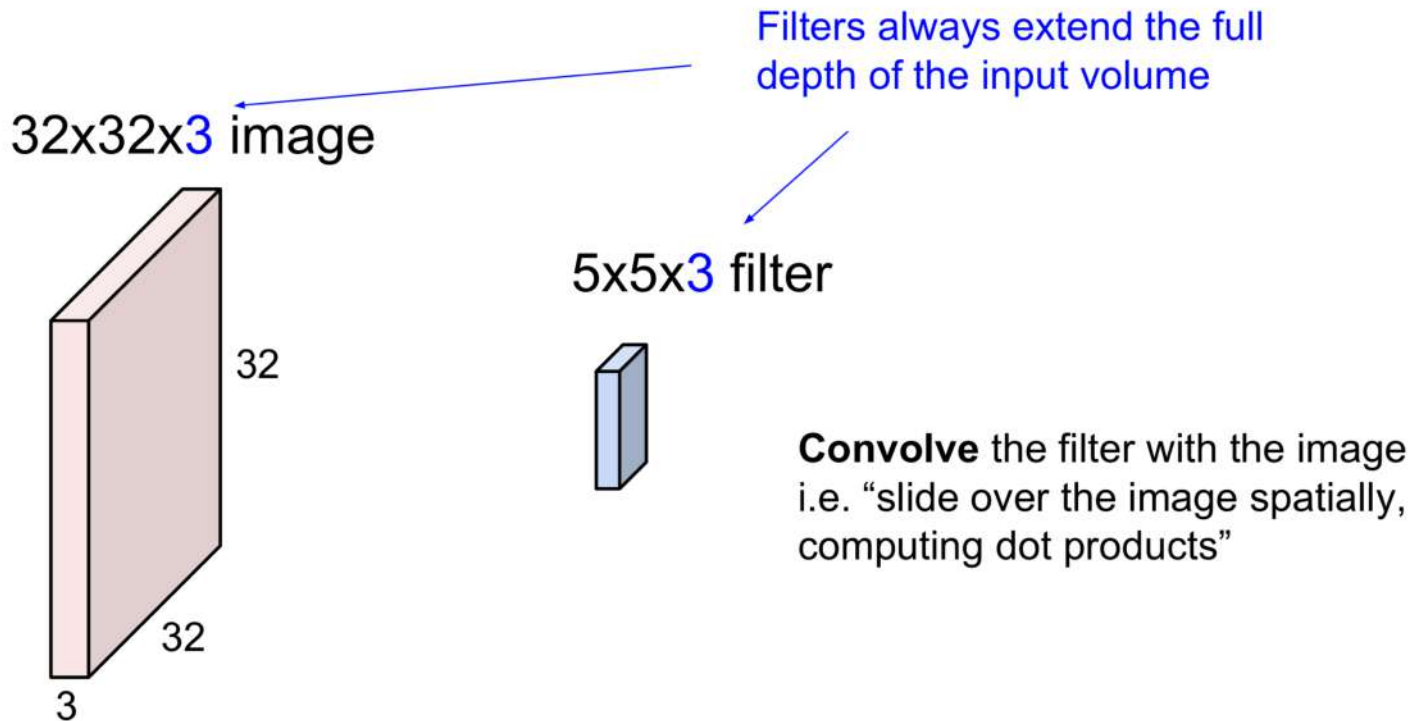


5x5x3 filter

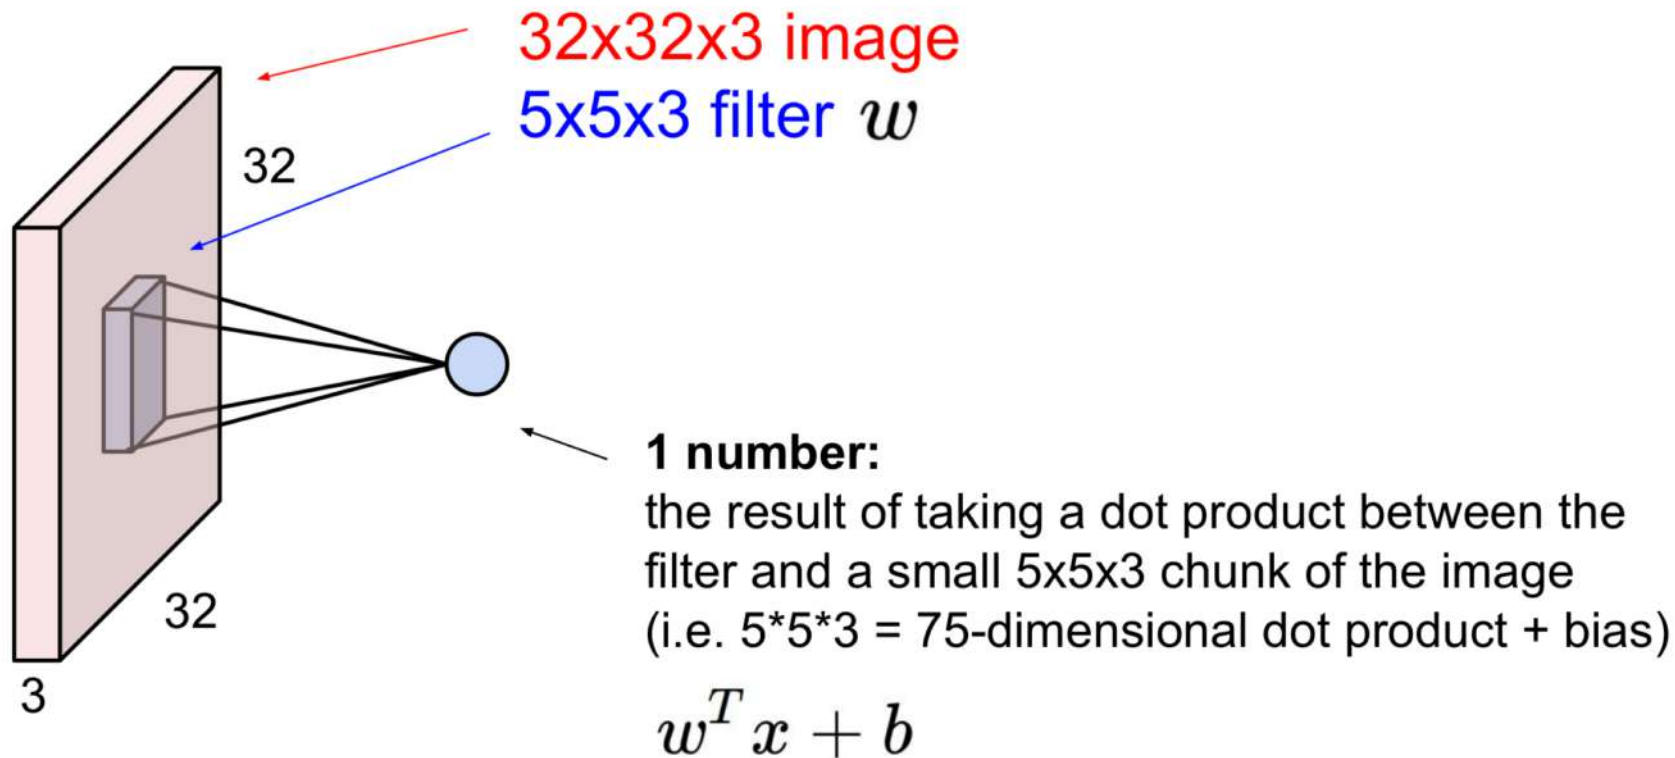


Convolve the filter with the image
i.e. “slide over the image spatially,
computing dot products”


Convolution Layer



Convolution Layer




Convolution Layer




Convolution Layer

똑같은 크기의 필터 6개를 더 만들어 봅시다



Convolution Layer

컨볼루션 네트워크는 활성화 함수를 포함한 컨볼루션
레이어의 연결입니다

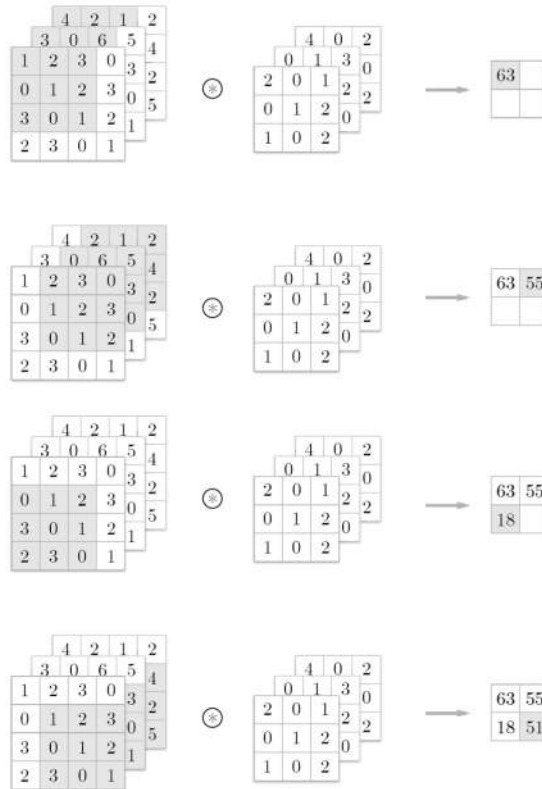


Convolution Layer



모두의연구소

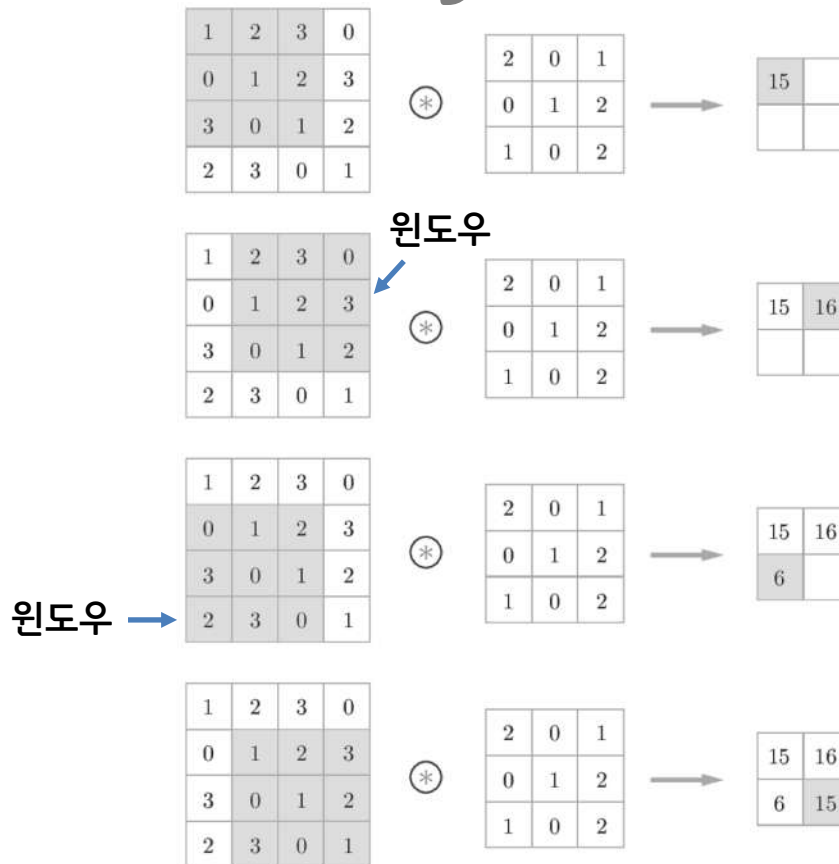
- 주의할 점은 입력데이터의 채널 수와 필터의 채널 수가 같아야 한다는 점
- 각 필터의 채널크기는 같아야 함



Convolution Layer


- 컨볼루션 연산

- 1) 윈도우를 일정 간격으로 이동해가며 입력 데이터에 적용
- 2) 입력과 필터에 대응하는 원소끼리 곱한 후 그 총합을 함 (단일 곱셈-누산 (fused multiply-add, FMA))
- Bias 파라미터 존재함



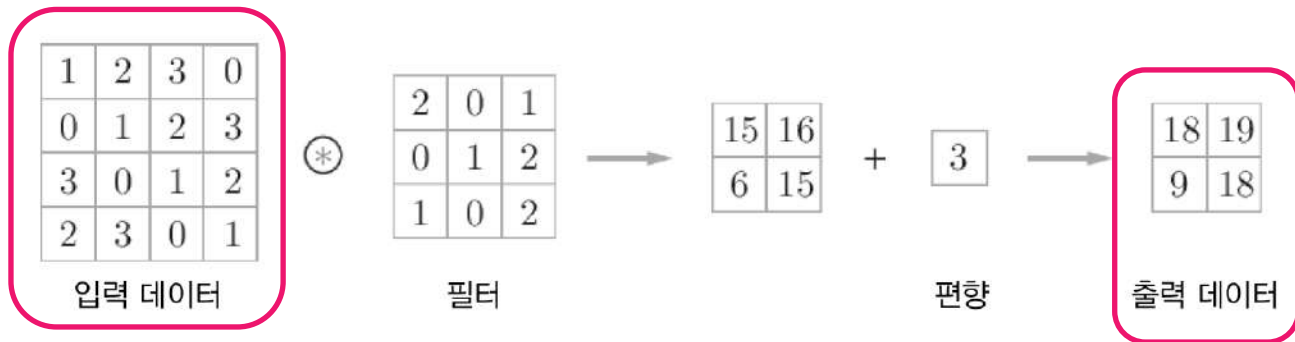
Convolution Layer

- 컨볼루션 연산



Convolution Layer

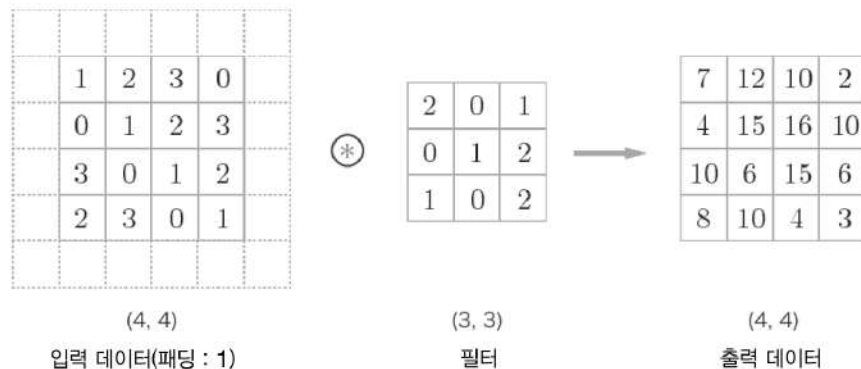
- 컨볼루션 연산



크기가 줄어드는 군요

Convolution Layer

- 패딩 (padding)
 - 컨볼루션 연산의 패딩 처리 : 입력 데이터 주위에 0을 채운다 (패딩은 점선으로 표시했으며 그 안의 값 '0'은 생략함)




- 패딩은 출력(특징맵(feature map))의 크기를 유지 시키고자 할때 주로 사용함

Convolution Layer


- 스트라이드 (stride)
 - 필터 적용하는 위치의 간격
 - 스트라이드를 2로 하면 필터를 적용하는 윈도우가 두 칸씩 이동함

- 스트라이드를 2로 하니 출력
이 3x3이 됨



특징맵의 크기변화

7




7x7 input (spatially)
assume 3x3 filter

7

특징맵의 크기변화


Replicate this column of hidden neurons across space, with some **stride**.



7x7 input
assume 3x3 connectivity, stride 1

특징맵의 크기변화


Replicate this column of hidden neurons across space, with some **stride**.



7x7 input
assume 3x3 connectivity, stride 1

특징맵의 크기변화


Replicate this column of hidden neurons across space, with some **stride**.



7x7 input
assume 3x3 connectivity, stride 1

특징맵의 크기변화

Replicate this column of hidden neurons across space, with some **stride**.




7x7 input

assume 3x3 connectivity, stride 1

특징맵의 크기변화


Replicate this column of hidden neurons across space, with some **stride**.



7x7 input
assume 3x3 connectivity, stride 1
=> **5x5 output**

특징맵의 크기변화

Replicate this column of hidden neurons across space, with some **stride**.




7x7 input
assume 3x3 connectivity, stride 1
=> **5x5 output**

what about stride 2?

특징맵의 크기변화

Replicate this column of hidden neurons across space, with some **stride**.




7x7 input
assume 3x3 connectivity, stride 1
=> **5x5 output**

what about stride 2?

특징맵의 크기변화

Replicate this column of hidden neurons across space, with some **stride**.



7x7 input

assume 3x3 connectivity, stride 1


=> **5x5 output**

what about stride 2?

=> **3x3 output**

특징맵의 크기변화

Replicate this column of hidden neurons across space, with some **stride**.




7x7 input
assume 3x3 connectivity, stride 1
=> **5x5 output**

what about stride 2?
=> **3x3 output**

what about stride 3? **Cannot.**

특징맵의 크기변화



Output size:

$$(N - F) / \text{stride} + 1$$

e.g. $N = 7, F = 3$:

$$\text{stride } 1 \Rightarrow (7 - 3) / 1 + 1 = 5$$

$$\text{stride } 2 \Rightarrow (7 - 3) / 2 + 1 = 3$$

$$\text{stride } 3 \Rightarrow (7 - 3) / 3 + 1 = \dots \backslash$$

특징맵의 크기변화

In practice: Common to zero pad the border

0	0	0	0	0	0			
0								
0								
0								
0								

e.g. input 7x7

3x3 filter, applied with **stride 1**

pad with 1 pixel border => what is the output?

(recall:)

$$(N - F) / \text{stride} + 1$$

특징맵의 크기변화

In practice: Common to zero pad the border

0	0	0	0	0	0			
0								
0								
0								
0								

e.g. input 7x7

3x3 filter, applied with **stride 1**

pad with 1 pixel border => what is the output?

7x7 output!

in general, common to see CONV layers with stride 1, filters of size $F \times F$, and zero-padding with $(F-1)/2$. (will preserve size spatially)

e.g. $F = 3 \Rightarrow$ zero pad with 1

$F = 5 \Rightarrow$ zero pad with 2

$F = 7 \Rightarrow$ zero pad with 3

특징맵의 크기변화

- 출력크기 계산해 보기

- 입력크기 : (H, W)
- 필터크기 : (FH, FW)
- 출력크기 : (OH, OW)
- 패딩 : P
- 스트라이드 : S

$$OH = \frac{H + 2P - FH}{S} + 1$$

$$OW = \frac{W + 2P - FW}{S} + 1$$

특징맵의 크기변화

- 출력크기 계산해 보기

입력 : (4,4), 패딩 : 1 , 스트라이드 : 1, 필터: (3,3)

$$OH = \frac{4 + 2 \cdot 1 - 3}{1} + 1 = 4$$

$$OH = \frac{H + 2P - FH}{S} + 1$$

$$OW = \frac{W + 2P - FW}{S} + 1$$

	1	2	3	0	
	0	1	2	3	
	3	0	1	2	
	2	3	0	1	

(4, 4)

입력 데이터(패딩 : 1)

⊗

2	0	1
0	1	2
1	0	2

(3, 3)

필터



7	12	10	2
4	15	16	10
10	6	15	6
8	10	4	3

(4, 4)

출력 데이터

특징맵의 크기변화

- 출력크기 계산해 보기

입력 : (7,7), 패딩 : 0 , 스트라이드 : 2, 필터: (3,3)

$$OH = \frac{7 + 2 \cdot 0 - 3}{2} + 1 = 3$$

$$OH = \frac{H + 2P - FH}{S} + 1$$

$$OW = \frac{W + 2P - FW}{S} + 1$$

스트라이드 : 2

1	2	3	0	1	2	3
0	1	2	3	0	1	2
3	0	1	2	3	0	1
2	3	0	1	2	3	0
1	2	3	0	1	2	3
0	1	2	3	0	1	2
3	0	1	2	3	0	1

⊗

2	0	1
0	1	2
1	0	2



15	17	

특징맵의 크기변화

- 출력크기 계산해 보기

입력 : (28, 31), 패딩 : 2 , 스트라이드 : 3, 필터: (5, 5)

$$OH = ? \qquad OH = \frac{H + 2P - FH}{S} + 1$$

$$OW = ? \qquad OW = \frac{W + 2P - FW}{S} + 1$$

특징맵의 크기변화

- 출력크기 계산해 보기

입력 : (28, 31), 패딩 : 2 , 스트라이드 : 3, 필터: (5, 5)

$$OH = \frac{28 + 2 \cdot 2 - 5}{3} + 1 = 10$$

$$OH = \frac{H + 2P - FH}{S} + 1$$

$$OW = \frac{W + 2P - FW}{S} + 1$$

$$OW = \frac{31 + 2 \cdot 2 - 5}{3} + 1 = 11$$

- OH, OW가 정수가 아니면?**


- 출력이 안나오는 것임. 오류를 내는 등의 대응 필요
- 딥러닝 프레임웍은 가까운 정수로 내림 하는 등, 특별히 에러를 내지않고 진행되도록 구현되는 경우가 많음

특징맵의 크기변화

Examples time:

Input volume: **32x32x3**

10 5x5 filters with stride 1, pad 2



Number of parameters in this layer?

특징맵의 크기변화




모두의연구소

Examples time:

Input volume: **32x32x3**

10 **5x5** filters with stride 1, pad 2




Number of parameters in this layer?

each filter has $5*5*3 + 1 = 76$ params (+1 for bias)

=> $76*10 = 760$


Pooling Layer

- makes the representations smaller and more manageable
- operates over each activation map independently:



Pooling Layer


- 세로·가로 방향의 공간을 줄이는 연산
 - 2x2 최대 풀링(max pooling)을 스트라이드 2로




- 평균 풀링(Average pooling)도 있습니다

Pooling Layer

- 풀링 계층의 특징
 - 학습해야 할 매개변수가 없음
 - 채널 수가 변하지 않음
 - 입력의 변화에 영향을 적게 받음 (강건하다)



데이터가 오른쪽으로 1칸씩 이동한 경우



Pooling 후 특징맵 크기 변화



Common settings:

$$F = 2, S = 2$$

$$F = 3, S = 2$$

- Accepts a volume of size $W_1 \times H_1 \times D_1$
- Requires three hyperparameters:
 - their spatial extent F ,
 - the stride S ,
- Produces a volume of size $W_2 \times H_2 \times D_2$ where:
 - $W_2 = (W_1 - F) / S + 1$
 - $H_2 = (H_1 - F) / S + 1$
 - $D_2 = D_1$
- Introduces zero parameters since it computes a fixed function of the input
- Note that it is not common to use zero-padding for Pooling layers

강아지 분류기




그림 : <https://www.quantamagazine.org/new-theory-cracks-open-the-black-box-of-deep-learning-20170921/>

Deep Visualization Toolbox

yosinski.com/deepvis

#deepvis



Jason Yosinski



Jeff Clune



Anh Nguyen



Thomas Fuchs

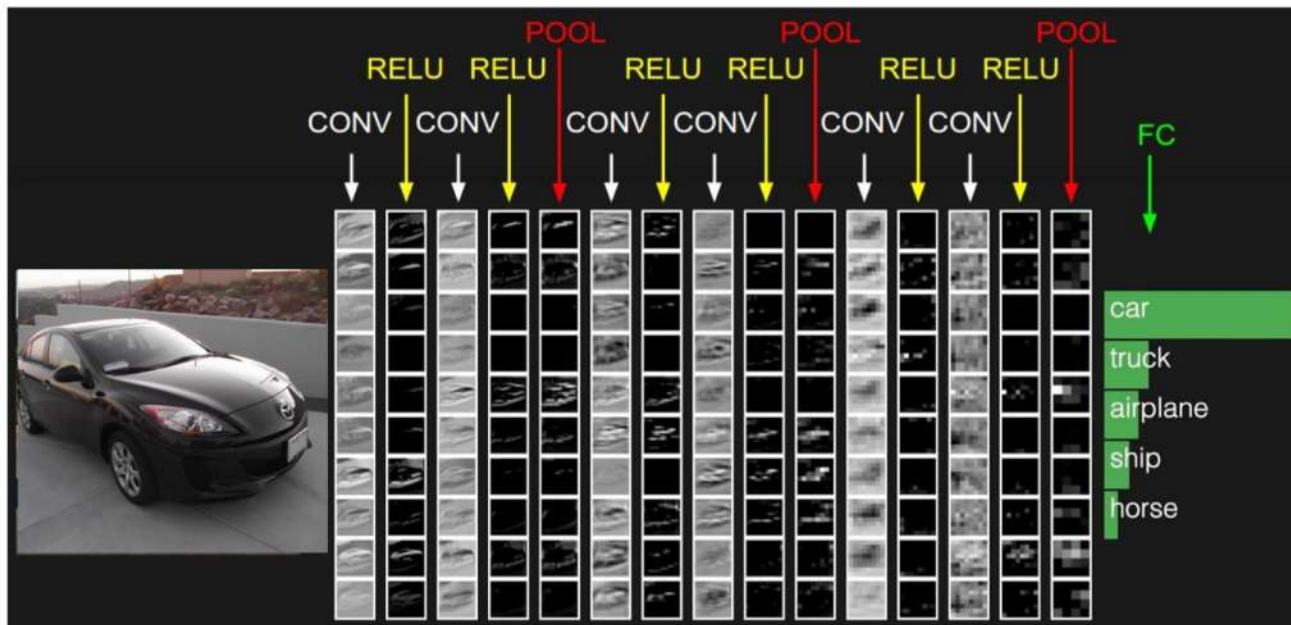


Hod Lipson



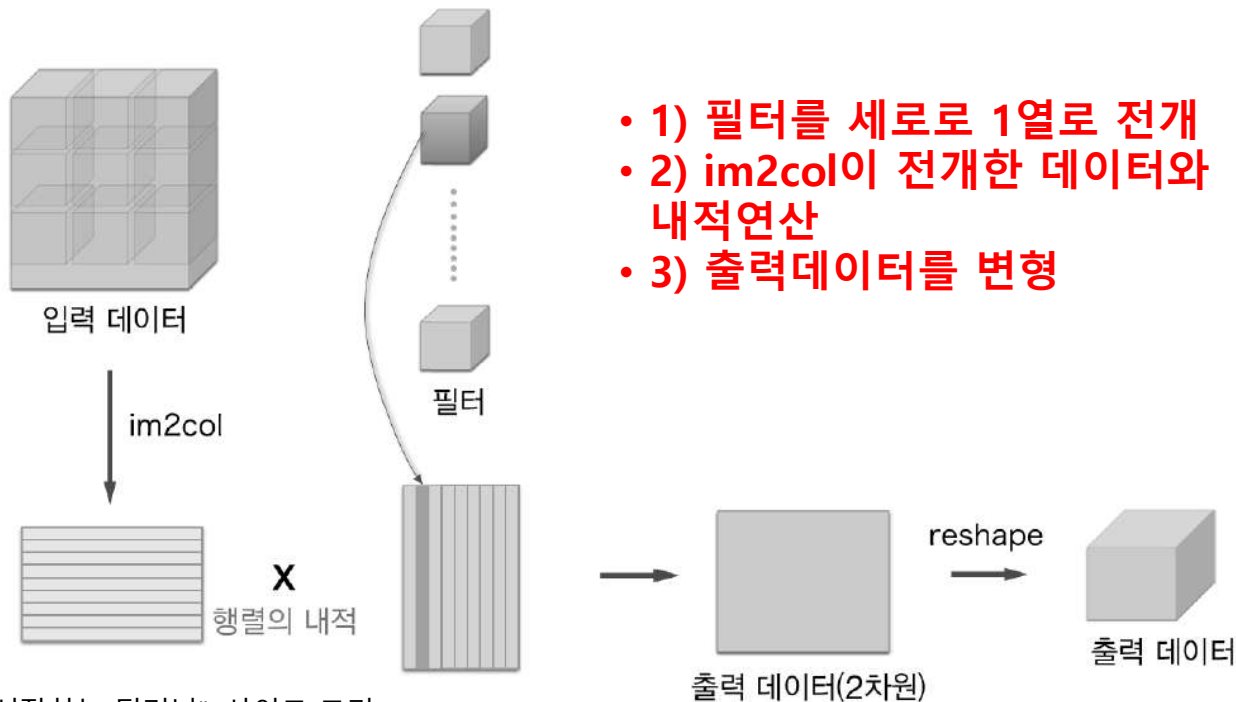
Fully Connected Layer (FC layer)

- Contains neurons that connect to the entire input volume, as in ordinary Neural Networks



Convolutional Networks 구현

- im2col로 데이터 전개하기
 - 합성곱을 행렬 곱 연산으로 (Affine 계층연산으로)

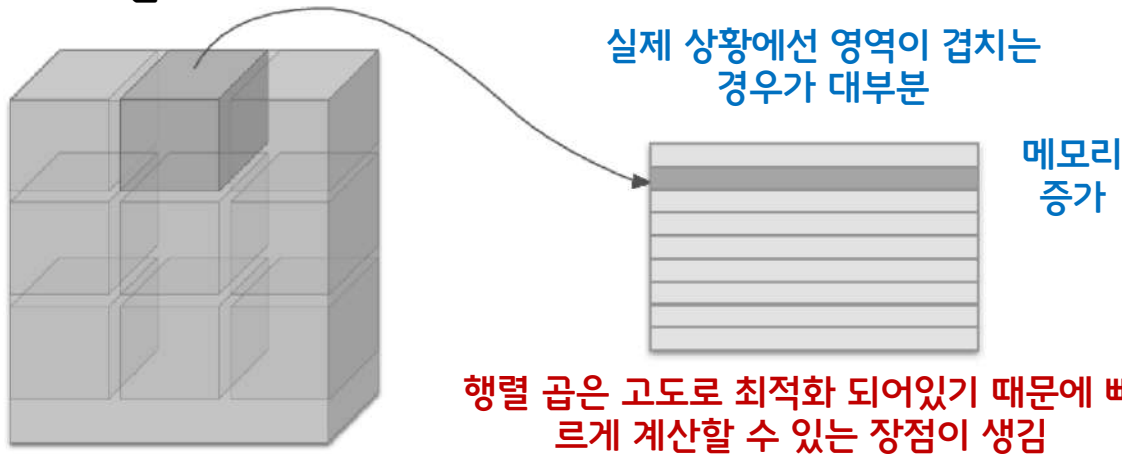


Convolutional Networks 구현



모두의연구소

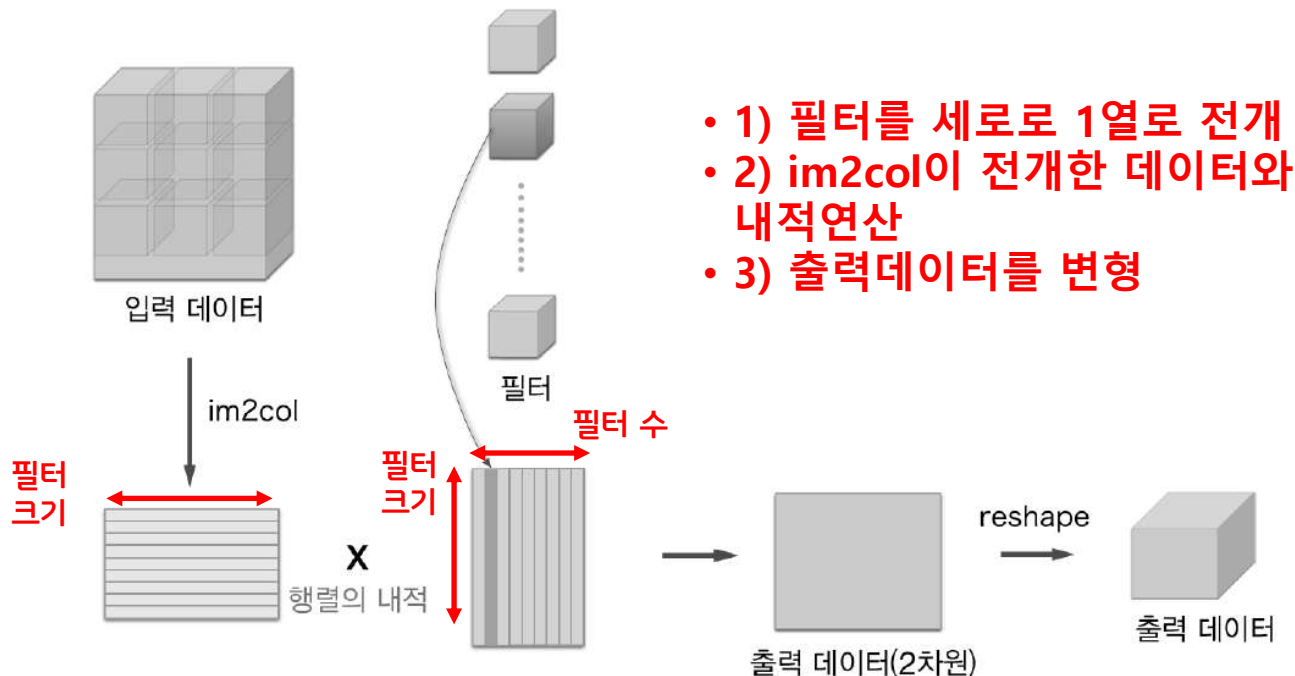
- im2col로 데이터 전개하기
 - 입력데이터에서 **필터를 적용하는 영역(3차원 블록)을 한줄로 늘어 놓습니다**
 - 이 전개를 필터를 적용하는 모든 영역에서 수행하는게 im2col입니다



필터 적용 영역을 앞에서부터 순서대로 1줄로 펼친다

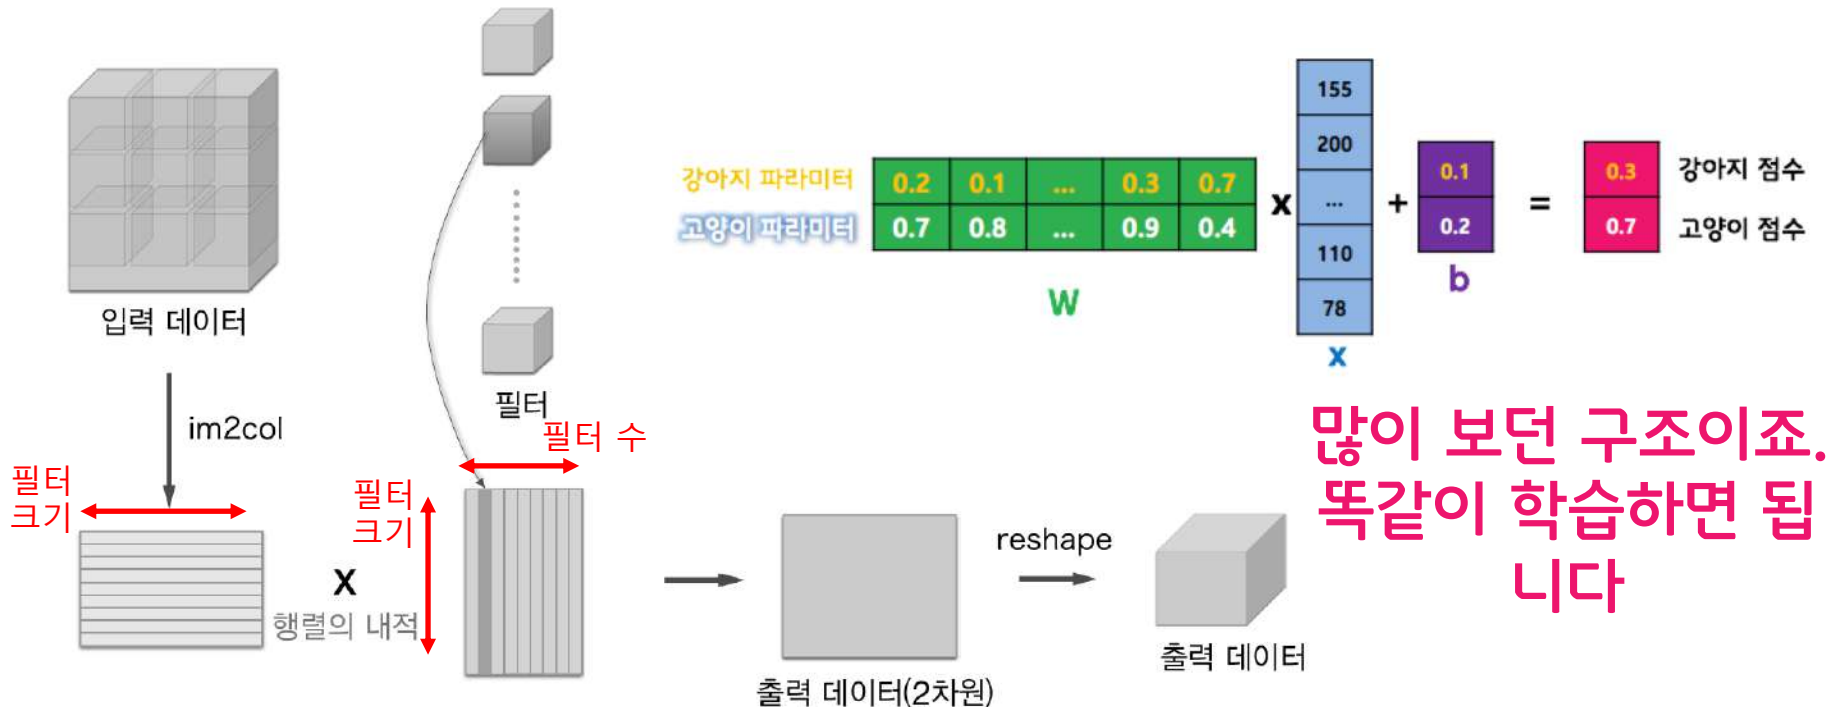
Convolutional Networks 구현

- im2col로 데이터 전개하기
 - 합성곱을 행렬 곱 연산으로 (Affine 계층연산으로)




Convolution 레이어 구현하기

- im2col로 데이터 전개하기
 - 합성곱을 행렬 곱 연산으로 (Affine 계층연산으로)




더 작은 필터

- 작은 필터로 더 깊게
 - 5x5 한번과 3x3 두번의 비교



더 작은 필터


- 작은 필터로 더 깊게
 - 5x5 한번과 3x3 두번의 비교



- 5x5와 같은 크기의 영역을 처리 (receptive field)
- 층이 깊어지기에 ReLU와 같은 비선형성 추가로 표현력이 개선. 비선형 함수가 겹쳐지면 더 복잡한것도 표현 가능

더 작은 필터


- 작은 필터로 더 깊게
 - 5x5 한번과 3x3 두번의 비교



- 매개변수 수 비교
 - 5x5 필터 1개 : 25개
 - 3x3 필터 2개 : $(3 \times 3) \times 2 = 18$ 개
 - 7x7 필터 1개 : 49개
 - 3x3 필터 3개 : $(3 \times 3) \times 3 = 27$ 개

CNN 예제

4_introduction-to-convnets-tensorflow.ipynb



모두의연구소

박 은 수 Research Director

E-mail : es.park@modulabs.co.kr